


Implementation

1. Cuda (B = 16)

Shared-memory

根據 Blocked Floyd-Warshall algorithm，每個 phase 的 dependency 關係如下圖所示：




可以得知每個 block 所需的 dependent block 其實最多只會有三個，因此在 shared memory 的配置上只要將相關的這三個 block 讀取進來即可。

那讀進 shared memory 之後需要將 index re-define，這邊 re-define 的方式就是將原本的 index 減掉原本所屬的 $(b_i, b_j) * B$ 後再加上 $n*B*B$ ，這邊的 n 決定於當初放進 shared-memory 時的順序。

Sequential address

在將 global memory 讀進 shared-memory 要特別注意，由於 GPU thread 開 2 維時 index 的標籤方式與 host 端 graph 的標籤方式不太一樣，如下圖所示：



因此在讀取 global memory 時若是單純使用 $i*V+j$ 的話，就會變成是藍色的箭頭一般跳著讀取 global memory 的值，使得效能低下。當將 index 方式改成 $j*V+i$ 後會變成是粉色箭頭，sequential 讀取 global memory 的值，效能也會突飛猛進。

Memcpy


我使用了 cudaMallocPitch / cudaMemcpy2D 來做 device 端記憶體的配置，那在 single 版本中由於 memcpy 並非主要 bottleneck，因此在效能上看不太出差別。

Stream

那由於在 phase2&3 時，會因為有 4 個方向導致有 4 個 kernel call，而每個 kernel 是 sequential 執行的，因此想說若是利用 stream 讓 4 個 kernel call 平行，那或許就能夠增加效能。但是事實證明這樣的想法並不成功，猜想原因應該是 GPU 的資源被吃滿了，就算增加平行度，沒有多餘的運算資源也沒用，後來想想也合理，因為若是單一 GPU 能夠 handle 4 個 kernel 的平行的話，就不需要 multi GPU 惹。

2. OpenMP (B = 16)

openMP 做法與 single version 差不多，差別在於只有在第三個 phase 時利用了兩張卡來加速。切割方式是切割成上下兩半，如下所示：



利用 phase 2 切出來的十字為界，將上下兩半（兩個顏色）切出來，接著將上下兩半在各自對半分，分別給兩張 GPU 卡做運算。而做完運算後的溝通這邊是利用 copy 回 host 再 copy 回自己所屬的 device_ptr 來做到。

Memcpy

那由於數量過多的 memcpy 會成為 bottleneck，因此使用 cudaMallocPitch / cudaMemcpy2D 會使效能上升不少。

Final version

那由於上述的版本實在太慢了，或許是優化不夠吧，因此最後的版本是會看看上下兩塊的大小是否夠大，夠大的話才會進行兩塊 GPU 的同時算，若是不夠大就單張卡各算各的。

3. MPI (B = 32)

MPI 做法與 openMP 的版本一樣，只是在溝通的地方換成 MPI_Isend / MPI_recv。

Profile (# vertex = 10000)

1. Cuba

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	49.21%	3.15164s	624	5.0507ms	22.816us	11.390ms	gpu_phase3_down(int*, int, int, int, unsigned long)
	48.33%	3.09555s	624	4.9608ms	22.625us	9.9037ms	gpu_phase3_up(int*, int, int, int, unsigned long)
	0.99%	63.198ms	1	63.198ms	63.198ms	63.198ms	[CUDA memcpy HtoB]
	0.96%	61.730ms	1	61.730ms	61.730ms	61.730ms	[CUDA memcpy DtoH]
	0.28%	17.768ms	1248	14.237us	2.7840us	30.112us	gpu_phase2_ud(int*, int, int, int, int, int, unsigned long)
	0.19%	12.388ms	625	19.820us	18.016us	21.856us	gpu_phase2_lr(int*, int, int, int, unsigned long)
	0.04%	2.2470ms	625	3.5950us	3.3920us	10.080us	gpu_phase1(int*, int, int, int, unsigned long)
API calls:	69.66%	4.56960s	3748	1.2192ms	374ns	11.370ms	cudaLaunch
	27.92%	1.83167s	2	915.84ms	63.130ms	1.76854s	cudaMemcpy2D
	2.36%	154.55ms	1	154.55ms	154.55ms	154.55ms	cudaMallocPitch
	0.04%	2.4831ms	21236	116ns	92ns	14.251us	cudaSetupArgument
	0.01%	691.89us	94	7.3600us	275ns	306.36us	cuDeviceGetAttribute
	0.01%	510.69us	3748	136ns	102ns	12.485us	cudaConfigureCall
	0.00%	308.25us	1	308.25us	308.25us	308.25us	cuDeviceTotalMem
	0.00%	306.78us	1	306.78us	306.78us	306.78us	cudaFree
	0.00%	75.896us	1	75.896us	75.896us	75.896us	cuDeviceGetName
	0.00%	5.9020us	3	1.9670us	557ns	4.7640us	cuDeviceGetCount
	0.00%	1.6760us	2	838ns	372ns	1.3040us	cuDeviceGet

可以看到最大的 overhead 是在 phase 3

2. openMP

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	96.92%	12.5781s	2496	5.0393ms	18.048us	11.333ms	gpu_phase3(int*, int, int, int, int, unsigned long)
	1.46%	190.05ms	4	47.513ms	30.982ms	64.220ms	[CUDA memcpy HtoD]
	0.95%	122.70ms	4	30.674ms	30.395ms	31.094ms	[CUDA memcpy DtoH]
	0.64%	83.075ms	4992	16.641us	3.1360us	31.936us	gpu_phase2(int*, int, int, int, int, int, int, unsigned long)
	0.03%	4.3004ms	1250	3.4400us	3.1360us	10.785us	gpu_phase1(int*, int, int, int, int, int, unsigned long)
API calls:	95.47%	12.8110s	2506	5.1121ms	6.0850us	36.773ms	cudaDeviceSynchronize
	1.80%	241.37ms	1	241.37ms	241.37ms	241.37ms	cudaHostAlloc
	0.97%	129.86ms	8	16.233ms	8.2450us	129.71ms	cudaStreamCreate
	0.95%	127.28ms	2	63.640ms	62.959ms	64.321ms	cudaMemcpy2D
	0.46%	61.283ms	1	61.283ms	61.283ms	61.283ms	cudaFreeHost
	0.26%	35.228ms	8738	4.0310us	3.3270us	260.37us	cudaLaunch
	0.05%	7.3535ms	63662	115ns	90ns	251.97us	cudaSetupArgument
	0.01%	1.6192ms	8738	185ns	127ns	254.28us	cudaConfigureCall
	0.01%	1.1183ms	2	559.17us	524.20us	594.15us	cudaMallocPitch
	0.01%	1.0917ms	2	545.86us	415.37us	676.35us	cudaFree
	0.01%	1.0658ms	188	5.6680us	256ns	249.44us	cuDeviceGetAttribute
	0.00%	449.16us	2	224.58us	220.32us	228.84us	cuDeviceTotalMem
	0.00%	115.51us	2	57.754us	51.736us	63.772us	cuDeviceGetName
	0.00%	82.489us	6	13.748us	5.8490us	27.749us	cudaMemcpy2DAsync
	0.00%	8.0030us	3	2.6670us	615ns	3.7370us	cudaSetDevice
	0.00%	4.7950us	3	1.5980us	352ns	3.5830us	cuDeviceGetCount
	0.00%	2.2430us	4	560ns	311ns	1.2620us	cuDeviceGet
	0.00%	1.1840us	1	1.1840us	1.1840us	1.1840us	cudaGetDeviceCount

很明顯的，memcpy 的 overhead 大幅提升，因為兩個 GPU 需要溝通的緣故

3. MPI

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	97.17%	10.7485s	1248	8.6126ms	18.272us	17.277ms	gpu_phase3(int*, int, int, int, int, unsigned long)
	1.50%	166.45ms	2	83.224ms	57.397ms	109.05ms	[CUDA memcpy HtoD]
	0.91%	101.07ms	2	50.533ms	47.067ms	53.999ms	[CUDA memcpy DtoH]
	0.39%	43.496ms	2496	17.426us	3.7120us	29.248us	gpu_phase2(int*, int, int, int, int, int, int, unsigned long)
	0.02%	2.4062ms	625	3.8490us	3.6160us	4.0640us	gpu_phase1(int*, int, int, int, int, int, unsigned long)
Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	97.22%	10.9000s	1248	8.7339ms	18.304us	17.474ms	gpu_phase3(int*, int, int, int, int, unsigned long)
	1.49%	167.25ms	2	83.624ms	56.550ms	110.70ms	[CUDA memcpy HtoD]
	0.88%	98.586ms	2	49.293ms	44.828ms	53.758ms	[CUDA memcpy DtoH]
	0.39%	43.449ms	2496	17.407us	4.0970us	29.344us	gpu_phase2(int*, int, int, int, int, int, int, unsigned long)
	0.02%	2.4217ms	625	3.8740us	3.6480us	4.1280us	gpu_phase1(int*, int, int, int, int, int, unsigned long)


Experiment (all on GeForce 1080)

1. System spec

課程提供的平台，使用 GeForce 1080

2. Weak scalability

Weak Scability (B = 16)




可以看到 openmp 和 cuda 差不多，差別在於某些 round 的 phase3 會分工並且以 memcpy 做溝通，那很明顯的，我的程式並沒有讓兩張 GPU 的優勢顯現出來，反而還因為 mamcpy 的關係造成某些 overhead。


那 mpi 的部分就更誇張了，溝通的成本超級大，我想這應該是程式內有某些邏輯上的 bug 導致的。

3. Time distribution

Time distribution - B = 8 / # V = 10000



Time distribuion B = 16 / #V = 10000



時間的計算：

compute / memcpy 都是利用 nvprof 的資料，而溝通的部分是利用 gettimeofday 來做計算。


有幾點觀察：

- I. 在 B = 8 時 compute time 皆比 B = 16 來得高，這點與 Blocking Factor 的實驗結論相吻合，推測就是平行效果不夠好。
- II. 這邊推翻上述所言，mpi 的溝通成本其實只多了一點點，主要是 compute 時間比其他兩者高，這點是因為為了要能夠比較好的傳送資料給別人，因此在 index 上有做一點修改，使得能夠以 row 為單位作傳送，猜測為這點的差別。
- III. openmp 以及 mpi 的 memcpy 時間都相對較高，因為需要把 device 的資料 copy 回 host 才能做溝通。

4. Blocking Factor

可以看出在 block factor = 16 時會有最佳效能。那探究其原因的話，在 B = 8 時會使得 round 數過多導致 call kernel 的次數增加，這或許是一個 overhead，因為並沒有達到好的平行效果。

而 B = 32 的時候也會些微變差，這邊猜測是因為當單一 block 裡的 thread 數增加時，因為 kernel 裡有兩層 for 迴圈，而造成更多 branch 導致效能些微下降。




5. Optimization

這是很底層的優化，所以三個版本都有做，因此以下只 demo cuda 版

1. Sequential address


Sequential address



看得出來在 Global memory 端是否有 sequential 讀取資料會使效能差距非常大

2. Shared memory

Shared memory



Shared memory的部分就不用說了，當然會提升效能

Conclusion

這次作業要我們 implement blocked Floyd-warshall algorithm on GPU，本身的演算法並不難實作，難的在於要如何加速，而要做到好的加速必須要對 GPU 的整個硬體構造（memory 等）相當了解才行，因此這次作業我認為算是最有難度的一次。

那 openMP 以及 MPI 其實算是屍體，畢竟沒有比單一 GPU 來得快，要如何做到溝通方面的加速也是我至今無法太理解的部分。